```
# 1.1 Import Library
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import warnings
warnings.filterwarnings('ignore')
import pandas as pd
# Load file CSV baru
df = pd.read_csv("Sales_Transaction_Intermediate_Original.csv")
# Konversi kolom tanggal
df['Date'] = pd.to_datetime(df['Date'], errors='coerce')
# Tambahkan kolom bulan
df['Month'] = df['Date'].dt.month
# Cek distribusi bulan
print(df['Month'].value_counts().sort_index())
→ Month
           34808
           27409
     2
           36259
     3
     4
           29466
           36578
     5
     6
           36440
     7
           39041
     8
           34935
     9
           49767
     10
           60145
     11
           84047
     12
           67455
     Name: count, dtype: int64
# 1.2 Load Data
df = pd.read_csv('Sales_Transaction_Intermediate_Original.csv')
df.shape
→ (536350, 8)
# 1.3 Salin data ke df_cleaned untuk proses cleaning
df_cleaned = df.copy()
# 1.4 Cek Struktur Awal
df_cleaned.info()
df_cleaned.head()
    <class 'pandas.core.frame.DataFrame'>
     RangeIndex: 536350 entries, 0 to 536349
     Data columns (total 8 columns):
                        Non-Null Count
                                          Dtype
     # Column
     ---
          -----
         TransactionNo 536350 non-null object
     0
                         536350 non-null
      1
         Date
                                          object
      2
         ProductNo
                         536350 non-null
                                          object
      3
          ProductName
                         536350 non-null
                                          object
      4
         Price
                         536350 non-null
                                          float64
          Quantity
                         536350 non-null int64
          CustomerNo
                         536295 non-null
                                          float64
                         536350 non-null object
         Country
     dtypes: float64(2), int64(1), object(5)
     memory usage: 32.7+ MB
        TransactionNo
                            Date ProductNo
                                                                ProductName Price Quantity CustomerNo
                                                                                                                Country
      0
                581482 12/9/2019
                                      22485
                                                 Set Of 2 Wooden Market Crates
                                                                              21.47
                                                                                           12
                                                                                                  17490.0 United Kingdom
      1
                581475 12/9/2019
                                      22596 Christmas Star Wish List Chalkboard
                                                                              10.65
                                                                                          36
                                                                                                  13069.0 United Kingdom
                581475 12/9/2019
                                      23235
      2
                                                       Storage Tin Vintage Leaf
                                                                              11.53
                                                                                           12
                                                                                                  13069.0 United Kingdom
      3
                581475 12/9/2019
                                      23272
                                                Tree T-Light Holder Willie Winkie
                                                                              10.65
                                                                                           12
                                                                                                  13069.0 United Kingdom
                581475 12/9/2019
                                      23239
                                              Set Of 4 Knick Knack Tins Poppies
                                                                                                  13069.0 United Kingdom
      4
                                                                             11.94
                                                                                           6
```

```
df.columns
```

```
dtype='object')
```

```
# Hapus duplikat
df_cleaned.drop_duplicates(inplace=True)

# Hapus nilai kosong pada kolom penting (dengan nama baru)
df_cleaned.dropna(subset=['TransactionNo', 'ProductNo', 'ProductName', 'Quantity', 'Date', 'Price', 'CustomerNo', 'Country'], inplace=Tr
# Hapus transaksi batal (yang diawali huruf "C")
df_cleaned = df_cleaned[~df_cleaned['TransactionNo'].astype(str).str.startswith('C')]

# Hapus nilai Quantity dan Price yang tidak valid
df_cleaned = df_cleaned[(df_cleaned['Quantity'] > 0) & (df_cleaned['Price'] > 0)]

# Ubah kolom tanggal
df_cleaned['Date'] = pd.to_datetime(df_cleaned['Date'])

# Tambahkan kolom Revenue
df_cleaned['Revenue'] = df_cleaned['Quantity'] * df_cleaned['Price']

# Filter hanya tahun 2019
df_cleaned = df_cleaned[df_cleaned['Date'].dt.year == 2019]
df_cleaned.head()
```

₹		TransactionNo	Date	ProductNo	ProductName	Price	Quantity	CustomerNo	Country	Revenue
	0	581482	2019-12-09	22485	Set Of 2 Wooden Market Crates	21.47	12	17490.0	United Kingdom	257.64
	1	581475	2019-12-09	22596	Christmas Star Wish List Chalkboard	10.65	36	13069.0	United Kingdom	383.40
	2	581475	2019-12-09	23235	Storage Tin Vintage Leaf	11.53	12	13069.0	United Kingdom	138.36
	3	581475	2019-12-09	23272	Tree T-Light Holder Willie Winkie	10.65	12	13069.0	United Kingdom	127.80
	4	581475	2019-12-09	23239	Set Of 4 Knick Knack Tins Poppies	11.94	6	13069.0	United Kingdom	71.64

```
# Hapus duplikat
df_cleaned.drop_duplicates(inplace=True)

# Hapus nilai kosong pada kolom penting
df_cleaned.dropna(subset=['TransactionNo', 'ProductNo', 'ProductName', 'Quantity', 'Date', 'Price', 'CustomerNo', 'Country'], inplace=Tr

# Hapus transaksi batal (yang diawali huruf "C")
df_cleaned = df_cleaned[~df_cleaned['TransactionNo'].astype(str).str.startswith('C')]

# Hapus nilai Quantity dan Price yang tidak valid
df_cleaned = df_cleaned[(df_cleaned['Quantity'] > 0) & (df_cleaned['Price'] > 0)]

# ② Ubah kolom tanggal dengan aman
df_cleaned['Date'] = pd.to_datetime(df_cleaned['Date'], dayfirst=True, errors='coerce')

# ② Hapus baris yang gagal diubah jadi datetime (NaT)
df_cleaned = df_cleaned.dropna(subset=['Date'])

# ② Filter hanya tahun 2019
df_cleaned = df_cleaned[df_cleaned['Date'].dt.year == 2019]
```

```
# Tambahkan kolom Revenue
df_cleaned['Quantity'] * df_cleaned['Price']
```

df_cleaned.head()

_		TransactionNo	Date	ProductNo	ProductName	Price	Quantity	CustomerNo	Country	Revenue	
	0	581482	2019-09-12	22485	Set Of 2 Wooden Market Crates	21.47	12	17490.0	United Kingdom	257.64	
	1	581475	2019-09-12	22596	Christmas Star Wish List Chalkboard	10.65	36	13069.0	United Kingdom	383.40	
	2	581475	2019-09-12	23235	Storage Tin Vintage Leaf	11.53	12	13069.0	United Kingdom	138.36	
	3	581475	2019-09-12	23272	Tree T-Light Holder Willie Winkie	10.65	12	13069.0	United Kingdom	127.80	
	4	581475	2019-09-12	23239	Set Of 4 Knick Knack Tins Poppies	11.94	6	13069.0	United Kingdom	71.64	

```
# 1.5 Tambahkan kolom bulan
df_cleaned['Month'] = df_cleaned['Date'].dt.month
# Cek bulan yang tersedia
df_cleaned['Month'].value_counts().sort_index()
df_cleaned.head()
```

7		TransactionNo	Date	ProductNo	ProductName	Price	Quantity	CustomerNo	Country	Revenue	Month
	0	581482	2019-12-09	22485	Set Of 2 Wooden Market Crates	21.47	12	17490.0	United Kingdom	257.64	12
	1	581475	2019-12-09	22596	Christmas Star Wish List Chalkboard	10.65	36	13069.0	United Kingdom	383.40	12
	2	581475	2019-12-09	23235	Storage Tin Vintage Leaf	11.53	12	13069.0	United Kingdom	138.36	12
	3	581475	2019-12-09	23272	Tree T-Light Holder Willie Winkie	10.65	12	13069.0	United Kingdom	127.80	12
	4	581475	2019-12-09	23239	Set Of 4 Knick Knack Tins Poppies	11.94	6	13069.0	United Kingdom	71.64	12

2. Segmentasi Produk Berdasarkan Volume dan Revenue


```
#Kita akan mengelompokkan produk berdasarkan performa penjualan: total quantity (volume transaksi) dan revenue.
#Hasil akhirnya adalah kategori produk: Super Popular, Popular, Normal, dan Low.
#Hitung total volume dana revenue per produk
product_df = df_cleaned.groupby('ProductName').agg({
    'Quantity': 'sum',
'Revenue': 'sum'
}).reset_index()
product_df.rename(columns={
    'Quantity': 'TransactionVolume',
    'Revenue': 'RevenueTotal'
}, inplace=True)
#Hitung kuartil volume dan revenue
volume_q3 = product_df['TransactionVolume'].quantile(0.75)
volume_q1 = product_df['TransactionVolume'].quantile(0.25)
revenue_q3 = product_df['RevenueTotal'].quantile(0.75)
revenue_q1 = product_df['RevenueTotal'].quantile(0.25)
#buat kolom segmentasi voolume dan revenue
def volume_segment(volume):
    if volume >= volume_q3:
        return 'High'
    elif volume <= volume_q1:</pre>
       return 'Low'
    else:
        return 'Medium'
def revenue_segment(revenue):
    if revenue >= revenue_q3:
       return 'High'
    elif revenue <= revenue_q1:</pre>
       return 'Low'
    else:
        return 'Medium'
product_df['VolumeSegment'] = product_df['TransactionVolume'].apply(volume_segment)
product_df['RevenueSegment'] = product_df['RevenueTotal'].apply(revenue_segment)
#Buat kolom segmentasi akhir
def final_segment(row):
    if row['VolumeSegment'] == 'High' and row['RevenueSegment'] == 'High':
        return 'Super Popular'
    elif 'High' in [row['VolumeSegment'], row['RevenueSegment']] and 'Low' not in [row['VolumeSegment'], row['RevenueSegment']]:
        return 'Popular'
    elif row['VolumeSegment'] == 'Low' and row['RevenueSegment'] == 'Low':
        return 'Low'
    else:
        return 'Normal'
product_df['FinalSegment'] = product_df.apply(final_segment, axis=1)
#Visualisasi jumlah produk per segmen
plt.figure(figsize=(8,5))
sns.countplot(data=product_df, x='FinalSegment', order=['Super Popular', 'Popular', 'Normal', 'Low'], palette='viridis')
plt.title('Jumlah Produk per Segmen')
plt.xlabel('Segment')
plt.ylabel('Jumlah Produk')
plt.show()
```



Jumlah Produk per Segmen 1750 1500 1250 1000 500 250 Super Popular Popular Normal Low Segment

```
#Cek hasil
product_df['FinalSegment'].value_counts()
    FinalSegment
₹
                      1835
     Normal
     Low
                       877
     Super Popular
                       873
     Popular
                        91
     Name: count, dtype: int64
print(product_df.columns)
Index(['ProductName', 'TransactionVolume', 'RevenueTotal', 'VolumeSegment',
            'RevenueSegment', 'FinalSegment'],
           dtype='object')
#Hitung total volume dan revenue per produk
product_df = df_cleaned.groupby('ProductName').agg({
    'Quantity': 'sum',
    'Revenue': 'sum'
}).reset_index()
product_df.rename(columns={
    'Quantity': 'TransactionVolume',
    'Revenue': 'RevenueTotal'
}, inplace=True)
#Hitng batas atas dan bawah untuk 20%-60%-20%
# Untuk volume transaksi
volume_top20 = product_df['TransactionVolume'].quantile(0.80)
volume_bottom20 = product_df['TransactionVolume'].quantile(0.20)
# Untuk revenue total
revenue_top20 = product_df['RevenueTotal'].quantile(0.80)
revenue_bottom20 = product_df['RevenueTotal'].quantile(0.20)
#Segmentasi volume dan revenue
def volume_segment(volume):
   if volume >= volume_top20:
        return 'Popular'
    elif volume <= volume bottom20:
       return 'Low'
    else:
       return 'Normal'
def revenue_segment(revenue):
   if revenue >= revenue_top20:
        return 'Popular'
    elif revenue <= revenue_bottom20:</pre>
        return 'Low'
    else:
        return 'Normal'
```

```
product_df['VolumeSegment'] = product_df['TransactionVolume'].apply(volume_segment)
product_df['RevenueSegment'] = product_df['RevenueTotal'].apply(revenue_segment)
#Buta kolom finealsegment
def final_segment(row):
   if row['VolumeSegment'] == 'Popular' and row['RevenueSegment'] == 'Popular':
        return 'Super Popular'
    elif 'Popular' in [row['VolumeSegment'], row['RevenueSegment']] and 'Low' not in [row['VolumeSegment'], row['RevenueSegment']]:
       return 'Popular'
    elif row['VolumeSegment'] == 'Low' and row['RevenueSegment'] == 'Low':
       return 'Low'
    else:
        return 'Normal'
product_df['FinalSegment'] = product_df.apply(final_segment, axis=1)
#Visualisasi jumlah produk per segment
plt.figure(figsize=(8,5))
sns.countplot(data=product_df, x='FinalSegment', order=['Super Popular', 'Popular', 'Normal', 'Low'], palette='viridis')
plt.title('Jumlah Produk per Segmen ')
plt.xlabel('Segment')
plt.ylabel('Jumlah Produk')
plt.show()
<del>_</del>
```



#Cek hasil
product_df['FinalSegment'].value_counts()

FinalSegment
Normal 2097
Low 672
Super Popular 657
Popular 94
Name: count, dtype: int64

2. Segmentasi Produk Berdasarkan Volume dan Revenue (Metode 20-60-20)

```
Segmentasi dilakukan untuk mengelompokkan produk berdasarkan performa penjualannya.
Kita melihat dua indikator utama:
- **Volume Transaksi** (`Quantity`)
- **Total Revenue** (`Revenue`)
```

Produk dikelompokkan ke dalam tiga segmen untuk masing-masing indikator: - **Top 20%** \rightarrow `Popular`

- **Nop 20%** → Popular - **Middle 60%** → `Normal` - **Bottom 20%** → `Low`

2.1 Hitung Total Volume dan Revenue per Produk

Data dikelompokkan berdasarkan `ProductName`, lalu dihitung total quantity dan revenue untuk masing-masing produk.


```
### 2.2 Segmentasi Volume dan Revenue (20-60-20 Rule)
Menggunakan metode distribusi persentil:
```

- Volume ≥ 80% → `Popular`
- Volume ≤ 20% → `Low`
- Sisanya → `Normal`

```
Begitu juga untuk revenue.
### 2.3 Final Segment: Gabungan Volume dan Revenue
Produk kemudian dikategorikan ke dalam empat segmen:
- `Super Popular`: High di Volume **dan** Revenue
- `Popular`: High di salah satu (volume/revenue), dan tidak Low di satunya
- `Normal`: Kombinasi Medium
- `Low`: Low di kedua metrik
### 2.4 Hasil Segmentasi
Distribusi segmen produk:
- Normal: 1262 produk
- Low: 442 produk
- Super Popular: 415 produk
- Popular: 33 produk
### 2.5 Visualisasi
Grafik batang menunjukkan jumlah produk di tiap segmen.
### Insight:
- Mayoritas produk masuk dalam kategori `Normal`, sesuai ekspektasi 60% distribusi tengah.
- Hanya sebagian kecil produk yang `Super Popular`, yang menjadi fokus perhatian pada analisis selanjutnya.
- Segmentasi ini akan digunakan untuk analisis waktu dan strategi produk lebih lanjut.
       Cell In[76], line 9
\rightarrow
         - **Top 20%** → `Popular`
     SyntaxError: invalid character '→' (U+2192)
#Bandingkan produk super popular bulan juli vs novembar
#Filter data untuk bulan juli dan november
# Tambahkan kolom 'Month' agar lebih mudah filter
df_cleaned['Month'] = df_cleaned['Date'].dt.month
# Filter bulan Juli dan November
july_df = df_cleaned[df_cleaned['Month'] == 7]
november_df = df_cleaned[df_cleaned['Month'] == 11]
#Hitung volume dan revenue per produk masing-masing
july_product = july_df.groupby('ProductName').agg({
    'Quantity': 'sum',
    'Revenue': 'sum'
}).reset_index().rename(columns={
    'Quantity': 'TransactionVolume',
    'Revenue': 'RevenueTotal'
})
# NOVEMBER
november_product = november_df.groupby('ProductName').agg({
    'Quantity': 'sum',
'Revenue': 'sum'
}).reset_index().rename(columns={
    'Quantity': 'TransactionVolume',
    'Revenue': 'RevenueTotal'
})
#Hitung segmentasi ulang di masing masing bulan
def segment_products(df):
   v_top = df['TransactionVolume'].quantile(0.80)
   v_bottom = df['TransactionVolume'].quantile(0.20)
    r_top = df['RevenueTotal'].quantile(0.80)
   r_bottom = df['RevenueTotal'].quantile(0.20)
    def v_seg(v): return 'Popular' if v >= v_top else 'Low' if v <= v_bottom else 'Normal'
    def r_seg(r): return 'Popular' if r >= r_top else 'Low' if r <= r_bottom else 'Normal'
    df['VolumeSegment'] = df['TransactionVolume'].apply(v_seg)
    df['RevenueSegment'] = df['RevenueTotal'].apply(r_seg)
    def final seg(row):
        if row['VolumeSegment'] == 'Popular' and row['RevenueSegment'] == 'Popular':
            return 'Super Popular'
        elif 'Popular' in [row['VolumeSegment'], row['RevenueSegment']] and 'Low' not in [row['VolumeSegment'], row['RevenueSegment']]:
            return 'Popular'
        elif row['VolumeSegment'] == 'Low' and row['RevenueSegment'] == 'Low':
            return 'Low'
            return 'Normal'
```

```
df['FinalSegment'] = df.apply(final seg, axis=1)
# Terapkan ke Juli dan November
july_segmented = segment_products(july_product)
nov_segmented = segment_products(november_product)
#bandingkan produk super popular juli vs november
# Ambil hanya produk super popular
july_super = set(july_segmented[july_segmented['FinalSegment'] == 'Super Popular']['ProductName'])
nov_super = set(nov_segmented[nov_segmented['FinalSegment'] == 'Super Popular']['ProductName'])
# Produk yang hanya ada di Juli
only_july = july_super - nov_super
# Produk yang hanya ada di November
only_nov = nov_super - july_super
# Produk yang ada di keduanya
both = july_super & nov_super
print("Jumlah Produk Super Popular Juli:", len(july_super))
print("Jumlah Produk Super Popular November:", len(nov super))
print("Produk yang sama di kedua bulan:", len(both))
   Jumlah Produk Super Popular Juli: 493
     Jumlah Produk Super Popular November: 546
     Produk yang sama di kedua bulan: 275
import matplotlib.pyplot as plt
labels = ['Juli Saja', 'November Saja', 'Keduanya']
counts = [len(only_july), len(only_nov), len(both)]
plt.figure(figsize=(6,5))
sns.barplot(x=labels, y=counts, palette='pastel')
plt.title('Perbandingan Produk Super Popular: Juli vs November')
plt.ylabel('Jumlah Produk')
plt.show()
→▼
```

Perbandingan Produk Super Popular: Juli vs November



```
july_segmented['FinalSegment'].value_counts()
nov_segmented['FinalSegment'].value_counts()
```

```
→ FinalSegment
                      1718
     Normal
     Low
                       549
     Super Popular
                       546
     Popular
                        56
     Name: count, dtype: int64
def segment_products(df):
    # Hitung Q1 dan Q3 untuk Volume & Revenue
    v_q1 = df['TransactionVolume'].quantile(0.25)
    v_q3 = df['TransactionVolume'].quantile(0.75)
    r_q1 = df['RevenueTotal'].quantile(0.25)
    r_q3 = df['RevenueTotal'].quantile(0.75)
```


```
# Segmentasi Volume
    def v_seg(v):
        if v >= v_q3:
            return 'High'
        elif v \leftarrow v_q1:
            return 'Low'
        else:
            return 'Medium'
    # Segmentasi Revenue
    def r_seg(r):
        if r >= r_q3:
           return 'High'
        elif r <= r_q1:
           return 'Low'
        else:
            return 'Medium'
    df['VolumeSegment'] = df['TransactionVolume'].apply(v_seg)
    df['RevenueSegment'] = df['RevenueTotal'].apply(r_seg)
    # Final Segment
    def final seg(row):
        if row['VolumeSegment'] == 'High' and row['RevenueSegment'] == 'High':
            return 'Super Popular'
        elif 'High' in [row['VolumeSegment'], row['RevenueSegment']] and 'Low' not in [row['VolumeSegment'], row['RevenueSegment']]:
            return 'Popular'
        elif row['VolumeSegment'] == 'Low' and row['RevenueSegment'] == 'Low':
            return 'Low'
            return 'Normal'
    df['FinalSegment'] = df.apply(final seg, axis=1)
july_segmented = segment_products(july_product)
nov_segmented = segment_products(november_product)
july_segmented['FinalSegment'].value_counts()
nov_segmented['FinalSegment'].value_counts()
→ FinalSegment
     Normal
                      1440
     Super Popular
                       683
     Low
     Popular
                       56
     Name: count, dtype: int64
july_super = set(july_segmented[july_segmented['FinalSegment'] == 'Super Popular']['ProductName'])
nov_super = set(nov_segmented[nov_segmented['FinalSegment'] == 'Super Popular']['ProductName'])
only_july = july_super - nov_super
only_nov = nov_super - july_super
both = july_super & nov_super
print("Jumlah Produk Super Popular Juli:", len(july_super))
print("Jumlah Produk Super Popular November:", len(nov_super))
print("Produk yang sama di kedua bulan:", len(both))
    Jumlah Produk Super Popular Juli: 621
     Jumlah Produk Super Popular November: 690
     Produk yang sama di kedua bulan: 373
print("Juli:", july_product.shape[0])
print("November:", november_product.shape[0])
→ Juli: 2613
     November: 2869
super popular products = set(product df[product df['FinalSegment'] == 'Super Popular']['ProductName'])
df_cleaned['Month'] = df_cleaned['Date'].dt.month
monthly_super_counts = []
for month in range(1, 13):
    df_month = df_cleaned[df_cleaned['Month'] == month]
    products_in_month = set(df_month['ProductName'].unique())
```

```
super_in_month = super_popular_products & products_in_month
monthly_super_counts.append(len(super_in_month))

plt.figure(figsize=(10,6))
sns.barplot(x=list(range(1, 13)), y=monthly_super_counts, palette='viridis')
plt.title('Jumlah Produk Super Popular per Bulan (Segmentasi Tahunan)')
plt.xlabel('Bulan')
plt.ylabel('Jumlah Produk Super Popular')
plt.xticks(range(0,12), ['Jan','Feb','Mar','Apr','Mei','Jun','Jul','Agu','Sep','Okt','Nov','Des'])
plt.show()
```




Jumlah Produk Super Popular per Bulan (Segmentasi Tahunan)



```
cohort_df = df_cleaned[['CustomerNo', 'Date']].copy()
cohort_df.dropna(inplace=True) # pastikan tidak ada NaN
cohort_df['OrderMonth'] = cohort_df['Date'].dt.to_period('M')
cohort\_df['CohortMonth'] = cohort\_df.groupby('CustomerNo')['Date'].transform('min').dt.to\_period('M')
def get_month_diff(order, cohort):
    return (order.dt.year - cohort.dt.year) * 12 + (order.dt.month - cohort.dt.month)
cohort_df['CohortIndex'] = get_month_diff(
    cohort_df['OrderMonth'].dt.to_timestamp(),
    cohort_df['CohortMonth'].dt.to_timestamp()
)
cohort_pivot = cohort_df.pivot_table(
   index='CohortMonth',
   columns='CohortIndex'
    values='CustomerNo',
   aggfunc='nunique'
)
cohort_size = cohort_pivot.iloc[:,0]
retention = cohort_pivot.divide(cohort_size, axis=0)
import seaborn as sns
import matplotlib.pyplot as plt
plt.figure(figsize=(12, 6))
sns.heatmap(retention, annot=True, fmt='.0%', cmap='Blues')
plt.title('Cohort Analysis: Retention Rate per Bulan')
plt.xlabel('Bulan ke-')
plt.ylabel('Cohort (Bulan Pelanggan Pertama)')
plt.show()
```





Tahap 4 - Cohort Analysis: Analisis Retensi Pelanggan

Tujuan:

Mengukur sejauh mana pelanggan yang pertama kali membeli pada bulan tertentu kembali melakukan transaksi di bulan-bulan berikutnya. Ini

Langkah Analisis:

- Menentukan bulan pertama pelanggan melakukan pembelian (`CohortMonth`)
- 2. Mengelompokkan pelanggan ke dalam cohort berdasarkan bulan pembelian pertama
- 3. Menghitung jumlah pelanggan unik per bulan dalam cohort
- 4. Menghitung **retention rate**: rasio pelanggan yang kembali per bulan setelah pembelian pertama
- 5. Menampilkan hasil dalam bentuk heatmap

Interpretasi Visualisasi:

- Retensi pelanggan paling tinggi berasal dari cohort awal (Januari-Maret 2019), yang menunjukkan pelanggan di awal tahun lebih loyal.
- Setelah bulan ke-2 atau ke-3, retensi menurun drastis di hampir semua cohort.
- Ini menunjukkan bahwa sebagian besar pelanggan hanya bertransaksi 1-2 kali, lalu tidak kembali.

Insight:

- Tidak adanya program loyalitas atau insentif membuat sebagian besar pelanggan tidak melakukan pembelian ulang.
- Diperlukan strategi khusus seperti **loyalty program**, **email follow-up**, atau **diskon untuk pembelian kedua** agar pelanggan lebi

∑▼

Distribusi Frekuensi Pembelian per Customer

```
1600
1400
1200
1000
1000
400
12 3 4 5 6 7 8 9101112131415161718192@1222@4252@293032334353639414344454849515355565771818290197185

Jumlah Transaksi
```

```
# Hitung jumlah variasi harga per produk
price_variety = df_cleaned.groupby('ProductName')['Price'].nunique()
# Ambil produk dengan minimal 5 variasi harga
produk_bervariasi = price_variety[price_variety >= 5].index
korelasi_list = []
for produk in produk_bervariasi:
    subset = df_cleaned[df_cleaned['ProductName'] == produk]
    if subset['Quantity'].nunique() > 1:
        corr = subset['Price'].corr(subset['Quantity'])
        korelasi_list.append({'ProductName': produk, 'Correlation': corr})
corr_df = pd.DataFrame(korelasi_list)
corr_df = corr_df.dropna().sort_values(by='Correlation')
corr_df.head(10) # 10 produk paling sensitif terhadap harga
₹
                                 ProductName Correlation
                       Letter "D" Bling Key Ring
      1051
                                                 -0.855851
                                                 -0.833198
      936
                 Ivory Chandelier T-Light Holder
      1118
               Marie Antoinette Trinket Box Gold
                                                 -0.824716
      1482
                      Purple Gemstone Bracelet
                                                 -0.818881
      1055
                       Letter "L" Bling Key Ring
                                                 -0.814210
      1060
                       Letter "Y" Bling Key Ring
                                                 -0.800193
      1057
                       Letter "P" Bling Key Ring
                                                 -0.787971
       808
                    Green Birdhouse Decoration
                                                 -0.727960
      801
                          Gold Fishing Gnome
                                                 -0.727594
      1228 Ocean Scent Candle In Jewelled Box
                                                 -0.701712
```


```
# Pilih salah satu produk paling elastis
produk_terelastis = corr_df.iloc[0]['ProductName']

# Ambil datanya
produk_data = df_cleaned[df_cleaned['ProductName'] == produk_terelastis]

# Plot
import seaborn as sns
import matplotlib.pyplot as plt

plt.figure(figsize=(8,5))
sns.scatterplot(data=produk_data, x='Price', y='Quantity')
plt.title(f'Scatter Plot - {produk_terelastis}')
plt.xlabel('Harga')
plt.ylabel('Jumlah Terjual')
plt.grid(True)
nlt.show()
```





Tahap 5 - Price Sensitivity Analysis (Elastisitas Harga)

🎯 Tujuan:

Menganalisis seberapa sensitif suatu produk terhadap perubahan harga dengan melihat hubungan antara **Price** dan **Quantity**.

🔍 Langkah Analisis:

- 1. **Pilih produk dengan variasi harga mencukupi**
 - Hanya produk yang memiliki **minimal 5 variasi harga** yang dianalisis, agar korelasi bermakna.
- 2. **Hitung korelasi Price vs Quantity**
 - Jika korelasi **negatif**, maka produk tersebut cenderung **elastis terhadap harga**.
 - Korelasi didefinisikan sebagai hubungan linear antara harga dan kuantitas.
- 3. **Identifikasi produk paling sensitif**
 - Urutkan produk berdasarkan nilai korelasi paling negatif.

Hasil Analisis:

10 produk teratas dengan korelasi negatif terkuat antara harga dan kuantitas terjual:

Produk	Korelasi
Letter "D" Bling Key Ring	-0.86
Letter "L" Bling Key Ring	-0.82
Letter "Y" Bling Key Ring	-0.81
Letter "P" Bling Key Ring	-0.79
Gold Fishing Gnome	-0.73
Green Birdhouse Decoration	-0.69
1	

- - -

🖈 Insight:

- Produk dengan korelasi negatif kuat berarti **sensitif terhadap harga**.
- Harga yang naik akan membuat jumlah penjualan turun signifikan.
- Produk seperti "Bling Key Ring" dan "Gold Fishing Gnome" **tidak cocok untuk strategi kenaikan harga**.

Rekomendasi Bisnis:

- Hindari menaikkan harga untuk produk-produk elastis.
- Terapkan strategi seperti:
 - **Diskon terjadwal**
 - **Bundling**
 - **Promosi beli banyak lebih hemat**
- Gunakan harga sebagai alat taktis untuk mempertahankan volume penjualan produk elastis ini.

```
df_no_outlier = df_cleaned[(df_cleaned['Quantity'] > 0) & (df_cleaned['Quantity'] <= 100)]</pre>
# 1. Transaksi harian
transaksi = df_no_outlier.groupby(['Date', 'TransactionNo'])['Quantity'].sum().reset_index()
# 2. Rata-rata item per transaksi per hari
basket_daily = transaksi.groupby('Date')['Quantity'].mean()
basket_daily.head(10)
→ Date
     2019-01-04
                   216.916667
     2019-01-05
                   282.264151
     2019-01-06
                   366.500000
     2019-01-07
                   272.442308
     2019-01-09
                   161.250000
     2019-01-10
                   311.526316
     2019-01-11
                   211.962264
     2019-01-12
                   228.466667
     2019-01-13
                   210.372093
     2019-01-14
                   279.255319
     Name: Quantity, dtype: float64
transaksi_negara = df_no_outlier.groupby(['Country', 'TransactionNo'])['Quantity'].sum().reset_index()
basket_by_country = transaksi_negara.groupby('Country')['Quantity'].mean().sort_values(ascending=False)
basket_by_country.head(10)

→ Country

                              1236.500000
     Singapore
     Netherlands
                               983.743902
                               622.400000
     Japan
     Australia
                               583.500000
     Switzerland
                               561.666667
     Israel
                               495.111111
                               490.500000
     United Arab Emirates
     Canada
                               490.500000
                               487,142857
     Iceland
                               459.461538
     Norway
     Name: Quantity, dtype: float64
transaksi = df_cleaned.groupby(['Date', 'TransactionNo'])['Quantity'].sum().reset_index()
basket_daily = transaksi.groupby('Date')['Quantity'].mean()
import matplotlib.pyplot as plt
plt.figure(figsize=(12,5))
basket_daily.plot()
plt.title('Rata-rata Basket Size per Hari')
plt.xlabel('Tanggal')
plt.ylabel('Rata-rata Jumlah Item per Transaksi')
plt.grid(True)
plt.tight_layout()
plt.show()
→
                                                               Rata-rata Basket Size per Hari
        2000
      Rata-rata Jumlah Item per Transaksi
        1750
        1500
        1250
        1000
         750
         500
         250
```

2019-05

2019-07

Tanggal

2019-03

2019-01


2019-09

2019-11

```
# Jumlah item per transaksi
transaksi_negara = df_cleaned.groupby(['Country', 'TransactionNo'])['Quantity'].sum().reset_index()
# Hitung rata-rata basket size per negara
basket_by_country = transaksi_negara.groupby('Country')['Quantity'].mean().sort_values(ascending=False)
plt.figure(figsize=(10,6))
basket_by_country.head(10).plot(kind='bar', color='skyblue') # tampilkan 10 negara teratas
plt.title('Rata-rata Basket Size per Transaksi (Top 10 Negara)')
plt.ylabel('Rata-rata Item per Transaksi')
plt.xlabel('Negara')
plt.xticks(rotation=45)
plt.grid(True)
plt.tight_layout()
plt.show()
```

_→

Rata-rata Basket Size per Transaksi (Top 10 Negara)



Tahap 6 - Basket Size Analysis

🎯 Tujuan:

Menganalisis rata-rata jumlah produk yang dibeli dalam satu transaksi (**basket size**) untuk memahami pola belanja pelanggan:

- Apakah pelanggan cenderung membeli banyak item atau hanya sedikit?
- Apakah ukuran keranjang berbeda antar negara?

> Pembersihan Data:

- Transaksi dengan `Quantity <= 0` (retur atau error) **dihapus**.
- Transaksi dengan `Quantity > 100` dianggap sebagai **outlier** dan **dikeluarkan** dari analisis untuk menjaga fokus pada pola pelang

📈 Analisis 1: Basket Size per Hari

- Dihitung rata-rata jumlah item per transaksi **setiap hari**.
- Menunjukkan fluktuasi tren harian terhadap ukuran keranjang.
- Setelah pembersihan, basket size per hari berada dalam rentang yang wajar (tidak ekstrem).

📊 Analisis 2: Basket Size antar Negara


- Dihitung rata-rata jumlah item per transaksi untuk **setiap negara**.
- Negara seperti **Singapore, Netherlands, dan Norway** memiliki rata-rata basket size terbesar.
- Hal ini menunjukkan potensi perilaku pembelian dalam jumlah besar atau pelanggan lebih loyal di negara-negara tertentu.

💡 Insight:

```
7/7/25, 2:44 PM
                                                                         Repair.ipynb - Colab
    - **Rata-rata ukuran keranjang per hari** mencerminkan pola belanja stabil, meskipun naik-turun sedikit tiap hari.
    - **Negara tertentu** menunjukkan pola pembelian dalam jumlah lebih banyak per transaksi, yang bisa jadi target strategis untuk promosi
    - Setelah pembersihan, data menjadi lebih representatif dan cocok untuk analisis perilaku pelanggan ritel biasa.
    df_cleaned['Revenue'] = df_cleaned['Quantity'] * df_cleaned['Price']
```

```
revenue_per_day = df_cleaned.groupby('Date')['Revenue'].sum()
revenue_per_day.head(10)
    Date
\overline{\mathbf{x}}
     2019-01-04
                    102158.04
     2019-01-05
                    224901.37
     2019-01-06
                    267053.40
     2019-01-07
                    189507.91
     2019-01-09
                     95529.21
     2019-01-10
                    154767.95
     2019-01-11
                    358297.18
     2019-01-12
                    132285.59
     2019-01-13
                    118414.74
                    273397.19
     2019-01-14
     Name: Revenue, dtype: float64
```

```
import matplotlib.pyplot as plt
plt.figure(figsize=(12,5))
revenue_per_day.plot()
plt.title('Tren Penjualan Harian (Total Revenue)')
plt.xlabel('Tanggal')
plt.ylabel('Total Revenue')
plt.grid(True)
plt.tight_layout()
plt.show()
```



```
df_cleaned['Date'] = pd.to_datetime(df_cleaned['Date'], dayfirst=True, errors='coerce')
# Tambahkan kolom hari dari tanggal
df_cleaned['DayOfWeek'] = df_cleaned['Date'].dt.day_name()
# Group total revenue per hari dalam seminggu
revenue_per_dayofweek = df_cleaned.groupby('DayOfWeek')['Revenue'].sum()
# Urutkan sesuai urutan hari
day_order = ['Monday', 'Tuesday', 'Wednesday', 'Thursday', 'Friday', 'Saturday', 'Sunday']
revenue_per_dayofweek = revenue_per_dayofweek.reindex(day_order)
# Tampilkan hasil numeriknya
print(revenue_per_dayofweek)
```

₹

```
→ DayOfWeek
     Monday
                   9597722.64
     Tuesday
                          NaN
     Wednesday
                   4915292.23
     Thursday
                   9189140.44
                  11893123.06
     Friday
                  10341232.69
     Saturday
                  12447145.09
     Sunday
     Name: Revenue, dtype: float64
{\tt import\ matplotlib.pyplot\ as\ plt}
# Group total revenue per hari dalam seminggu
revenue_per_dayofweek = df_cleaned.groupby('DayOfWeek')['Revenue'].sum()
# Urutkan hari agar sesuai urutan kalender
day_order = ['Monday', 'Tuesday', 'Wednesday', 'Thursday', 'Friday', 'Saturday', 'Sunday']
revenue_per_dayofweek = revenue_per_dayofweek.reindex(day_order)
# Plot bar chart
plt.figure(figsize=(8, 5))
revenue_per_dayofweek.plot(kind='bar', color='skyblue')
plt.title('Total Revenue per Hari dalam Seminggu')
plt.xlabel('Hari')
plt.ylabel('Total Revenue')
plt.xticks(rotation=45)
plt.grid(axis='y')
plt.tight_layout()
plt.show()
```

